MAT3300 MATHEMATICAL MODELING · FINAL PROJECT

Problem C 深入理解与项目规划

2021 ICM Problem D — The Influence of Music
项目理解 · 数据检查 · 统一建模框架 · 实施方案

阅读目录

一、先用人话理解：这个项目到底在研究什么

二、课程要求怎样约束我们的方案

三、严格按官方顺序拆解七项 Requirements

四、四个数据文件到底提供了什么

五、统一框架应该怎样设计

六、Requirement–Model Mapping

七、两篇 Outstanding Winner papers 给我们的具体启发

八、两套可执行方案

九、Validation 和 Sensitivity Analysis 应该怎样安排

十、真正开始时的执行顺序

十一、我建议的最终项目结构

来源文件索引

可以把 Network + Similarity + Temporal Analysis 作为整个项目的主线，而且它与你现有的 Quant Research 经验很契合。 但我建议把这套框架理解为“共享数据与指标的分析系统”，而不是试图用一个公式回答七个问题。

最自然的研究顺序是：

> **先看谁被记录为影响了谁，再看他们的音乐是否相似，接着检查这种对应是否超出流派、年代等因素的解释，最后研究这些联系怎样伴随音乐风格的演变。**

这次我重新读取了 Guidelines、官方题目全部 5 页、四个 CSV，以及两篇优秀论文全部 23 页和 25 页，也实际检查了数据关联、重复记录、时间字段和汇总表一致性。所有指定文件都可以读取。

先把三个最重要的判断说在前面：

1. **七项要求可以组织成一个连贯项目，不需要七套互不相关的模型。**
2. **数据支持网络描述、风格比较和回顾性的时间分析，但不能直接识别真实影响发生的时间，也不足以证明因果传播。**
3. **当前最值得投入的不是复杂算法，而是数据口径、合理对照组和时间顺序。** 四个文件没有普通空值，但存在 ID 冲突、汇总口径不一致、日期异常等问题，远比“直接 merge 后跑模型”复杂。

以下把**官方要求、实际数据发现、参考论文方法和我的建议**分开说。

一、先用人话理解：这个项目到底在研究什么

1. 研究对象不是“什么音乐好听”，也不是“谁最红”

假设某位音乐人说：“我受到 The Beatles 的影响。”

这句话至少可以引出四个不同的问题：

- 有多少人承认受到 The Beatles 的影响?
- 这些人是否也影响了其他音乐人?
- 他们的作品，在节奏、能量、声学程度等方面，是否与 The Beatles 相似?
- 后来某种音乐风格的变化，是否与这些音乐人的作品变化、影响关系有对应?

题目希望把这些问题从口头描述变成**有定义、有计算结果、能够检查的量化分析**。

官方背景明确说，目标是理解和衡量**以前的音乐对新音乐及音乐人的影响**，并研究艺术家和流派的渐进演化与重大变化。它不是单纯做音乐分类，也不是单纯给音乐人排名。官方背景在第 1 页，七项要求均在第 2 页。

[来源 1] ProblemC_2021ICM-D_The_Influence_of_Music.pdf

2. Influence 至少要分成三个层次

层次	实际含义	数据能支持到什么程度
被报告的影响关系	某音乐人或行业专家认为 A 影响了 B	`influence_data` 直接记录
作品特征上的对应	A 与 B 在某些可观测音乐特征上相似，或变化方向相近	可以计算、比较和做统计核验
因果影响	如果 B 没有受到 A 的影响，B 的音乐就会不同	当前数据不能直接识别

这三个层次不能混用。

例如，A 与 B 都做某类音乐，即使不存在直接学习关系，也可能很像；反过来，B 可能从 A 学到了创作态度、舞台表现或歌词写法，而这些不在提供的数值特征中，因此数值上不一定很像。

所以，你们最终衡量的是“记录中的结构影响力”和“可观测风格关联”，并讨论它们与真实音乐影响之间的关系。

3. Influence Network 是什么

把音乐人画成点，把影响关系画成箭头：

$$\text{影响者} i \longrightarrow \text{追随者} j$$

例如数据中确实存在：

$$\text{The Beatles} \longrightarrow \text{David Bowie}$$

这里的箭头不是“二人合作过”，不是“歌曲相似”，也不是“粉丝关注”，而是**数据记录的音乐影响关系**。

整个网络可以帮助回答：

- 谁直接影响的人多?
- 谁影响了后来也很有影响力的人?
- 谁把不同流派连接起来?
- 某个流派主要受到哪些流派的影响?

4. Musical Features 与 Influence Relationships 的区别

可以把它们理解成两张不同类型的表：

- **关系表**：“谁与谁之间存在被报告的影响关系？”
- **特征表**：“某人的作品是什么样的？”

音乐特征包括：

- `danceability`：适不适合跳舞；
- `energy`：听起来有多强烈、有活力；
- `acousticness`：有多像原声音乐；
- `instrumentalness`：有多可能没有人声；
- `tempo`：节拍速度；
- `loudness`：响度；
- `valence`：音乐传达的积极情绪程度。

这些特征是对音乐的有限描述，不包含完整旋律、和声、歌词或录音内容。

5. 一个贯穿全项目的真实数据例子

以下是我核对文件后确认的事实：

- The Beatles 的 ID 是 `754032`；
- David Bowie 的 ID 是 `531986`；
- 影响表有 `754032 → 531986`；
- 两者的主流派均标为 `Pop/Rock`；
- 两者的 `active_start` 都是 `1960`，表示开始职业生涯的**年代**；
- 歌曲明细中，The Beatles 有 413 条音乐人署名记录，David Bowie 有 231 条；这是清洗前的统计。

从这里到模型，应这样走：

第一步：确认关系。
画出 The Beatles → David Bowie，再加入他们的其他前辈与追随者，形成一个小网络。

第二步：表示风格。
用一组音乐特征描述两人的作品。例如先分别计算作品的平均能量、平均节奏、平均原声程度，得到两个数值向量。

第三步：比较相似程度。
计算两个向量的距离，但不能只说“距离小，所以确实有影响”。还要比较：

> David Bowie 与 The Beatles 的相似程度，是否高于他与其他同流派、相近年代音乐人的相似程度?

第四步：加入时间。
只用某个时期之前的 The Beatles 作品，与 David Bowie 后续时期的作品比较，避免把后来作品反过来当成早期影响来源。

第五步：形成有分寸的结果。
如果未来分析发现存在额外相似性，可以说：

> 这条被报告的影响关系，在若干音乐特征上得到支持。

不能直接说：

> 模型证明 The Beatles 导致了 David Bowie 的风格变化。

另外，数据中 The Beatles 的作品记录一直延伸到 2014 年。**这只是文件里的发行年份，不能自动当作作品最初创作年份。** 这正是时间分析要特别小心的地方。

二、课程要求怎样约束我们的方案

这份项目首先是课程作业，方案应围绕评分要求组织。

Guidelines 明确规定：

- Problem C **只能使用指定四个数据文件**；
- 官方 Requirements 是项目规格；
- 优秀论文是参考，不是标准答案；
- Report 最多 25 页，包含 Summary Sheet、目录、正文、给 ICM Society 的一页说明和 References；
- 组队另加一页贡献说明，不计入 25 页；个人可省略；
- Slides 最多 8 页；
- 提交可复现全部图表和数字的代码、输入数据和 README；
- 截止时间是 **11 月 29 日 24:00**；
- Report、Slides、Q&A 分别占课程总成绩的 30、10、15 个百分点；

- Q&A 中每个成员都可能被问到任何部分。

Report 的五项重点是：**要求覆盖完整、模型正确、验证与敏感性分析、表达、代码可复现性**。没有要求模型越复杂越好，也没有给出这五项内部的具体分数分配。

[来源 2] Final_Project_Guidelines.pdf

对你们最实际的含义是：

> 一个完成七项要求、对照设计合理、数据口径清楚的简洁模型，比一个用上 GNN、但时间定义和验证说不清楚的项目更符合评分标准。

三、严格按官方顺序拆解七项 Requirements

下面的页码均为官方 Problem Statement 的 PDF 页码。**七项都在第 2 页**；第 3—5 页解释数据和提交内容。

Requirement 1：建立影响网络，定义影响力，并分析一个子网络

A. 官方到底要求什么?

使用全部或部分 `influence_data` 建立有向影响网络，开发衡量音乐影响力的参数；建立并描述一个子网络，解释这些指标在子网络中揭示了什么。

不是只要求一张网络图，也不是只要求一个排名。

B. 翻译成人话

> 谁影响的人多？谁的影响可能传到更远？在一个具体音乐圈子里，这些“重要人物”分别扮演什么角色?

C. 具体需要做什么

输入主要是影响表：

1. 建立音乐人节点表；
2. 定义影响者 → 追随者的有向边；
3. 定义两三个含义不同的影响力指标；
4. 选择一个有明确理由的子网络；

5. 结合人物、流派和指标解释结构。

子网络可以选：

- 一个流派的内部网络；
- 一个音乐人周围一至两层的关系；
- 两个存在大量跨流派联系的流派。

D. 合理模型

简单方案：

- **出度**：一个人直接影响了多少人；
- **追随者贡献分摊指标**：如果某位追随者列出了很多影响者，就把这位追随者的“认可”分摊给这些影响者；
- 跨流派追随者比例或数量：影响是否跨越流派。

适当进阶：

- 在**反向网络**上计算 PageRank，衡量“是否被重要追随者认可”；
- 对选定子网络计算 Betweenness，识别连接不同部分的桥梁。

不建议直接把五六个指标加权成一个总分，再把总分称为“真实影响力”。

E. 最终展示

- 一张可读的子网络图；
- 一张影响力指标对照表；
- 两三个具体角色的解释；
- 必要时展示排名对指标选择是否稳定。

F. 难点

最容易出错的是**方向**。原图是影响者 → 追随者，直接套 PageRank 默认的入边逻辑，得到的未必是你想要的“影响者地位”。

此外，全网排名与子网排名不是同一件事：一个人可能在本流派很重要，在全网并不突出。

Requirement 2：定义音乐相似性，比较流派内外

A. 官方要求

使用音乐明细和 / 或两个汇总数据集建立音乐相似性指标，并回答：同一流派的艺术家是否比不同流派的艺术家更相似?

B. 人话

> 你能不能用音乐特征合理地定义“像不像”？这个定义是否能发现同类音乐人通常更像?

C. 具体工作

1. 选哪些特征代表音乐风格；
2. 处理不同单位；
3. 形成音乐人特征向量；
4. 计算音乐人之间的相似性；
5. 比较同流派与跨流派配对；
6. 检查结论是否依赖某个特征或某种距离。

D. 模型选择

简单方案：

- 标准化后的 Euclidean Distance；
- 转成“越大越相似”的指标，例如 $1/(1+d)$。

进阶方案：

- Cosine Similarity 作为替代口径；
- PCA 后再计算距离，减少高度相关特征的重复计权。

PCA 的直观意思是：把经常一起变化的多个特征，压缩成少数几个综合方向。它可以帮助看结构，但综合方向不一定容易解释。

E. 最终展示

- 流派内与流派间相似性分布；
- 各流派之间的 Similarity Heatmap；
- 差异大小及不确定性；
- 原始特征或 PCA 空间中的辅助散点图。

F. 难点

- Pop/Rock 人数多，不能让它支配所有结果；
- 配对共享音乐人，不能把每对都当独立样本；
- 不能先根据流派标签把距离调到“同流派最像”，再用同一批流派标签证明指标有效；
- 同一个人与自己的相似度必须排除。

Requirement 3：比较流派之间的相似与影响，解释流派特征及其变化

A. 官方要求

比较流派内外的相似性与影响；解释什么区分了流派、流派如何随时间变化，以及一些流派是否彼此相关。

B. 人话

> 两个流派“听起来接近”和“历史关系密切”是不是一回事？各流派有什么典型特征？这些特征后来有没有变？

C. 具体工作

复用前两项结果：

1. 将音乐人之间的影响边汇总到流派层面；
2. 计算流派之间的风格距离；
3. 比较流派的特征分布；
4. 从歌曲明细构建流派—时期特征；
5. 看流派之间是在靠近、远离，还是保持差异。

D. 模型选择

简单方案：

- 流派影响矩阵；
- 流派相似性矩阵；
- 标准化特征均值与分布比较；
- 年代趋势。

进阶方案：

- 对流派影响矩阵做规模校正；
- 用简单可解释的分类模型辅助判断哪些特征有区分力。

分类模型只是辅助，不是本题必须完成的任务。

E. 最终展示

- 两张并列热力图：影响关系、风格相似性；

- 流派特征分布图；
- 若干主要特征的时间曲线；
- 一个“结构关系强但数值风格不很像”或相反的案例。

F. 难点

- 边数量多可能只是流派规模大；
- 音乐人的 `main_genre` 是固定标签，不是每首歌曲的真实流派；
- 流派平均值变化可能来自新音乐人进入，而不一定是原有音乐人改变风格。

Requirement 4：影响关系是否得到作品相似性的支持，哪些特征更“易传播”

A. 官方要求

判断被识别的影响者是否真的影响了追随者的音乐，并分析是否有一些音乐特征比其他特征更“contagious”。

原文这一项写了 `data_influence`，但实际附件名是 `influence_data.csv`；文件里也没有现成的相似度列。因此应理解为：**用自己建立的相似性指标核验被报告的影响关系。**

B. 人话

> 这些关系只是“被人说过”，还是能在作品特征里看到对应？如果有对应，是能量、节奏、原声程度，还是别的东西更明显？

C. 具体工作

这一项必须有**对照**。

例如固定一个追随者 B：

- 看 B 与其记录中的影响者 A 有多像；
- 再看 B 与其他同类、相近年代、没有记录影响边的音乐人有多像；
- 比较两者差异。

随后对每个特征单独做这种比较。

“没有记录影响边”不能说成“确定没有影响”，它只是数据里的比较组。

D. 模型选择

简单而有力的方案：

- 流派、出道年代等条件匹配；
- 关系配对与对照配对的距离差；
- 随机重排或重抽样，判断结果是否稳定。

这里的随机重排，不是随便打乱所有东西，而是在合理限制下重新分配配对，观察“没有特定配对结构时”通常会得到多大差异。

适当进阶：

- 在有足够时间记录的样本中，比较影响者较早作品与追随者较晚作品；
- 用带控制变量的回归检验额外关联。

E. 最终展示

- 关系组与匹配对照组的相似性分布；
- 每个特征的差异及区间；
- 一两个音乐人的具体核验案例；
- 更严格时间筛选下结果是否保留。

F. 难点

这是全项目最需要统计判断的一项：

- 同流派、同年代可能同时解释关系与相似；
- 同一音乐人出现在很多配对中，造成观测依赖；
- 高相关不代表传播；
- 低相似也不等于否定关系，因为影响可能体现在未观测的旋律或歌词上；
- 多个特征同时检验，要控制“总能碰巧找出一个显著结果”的问题。

我的建议是把结论写成：

> 哪些被报告的影响关系，在可观测风格上得到额外支持；哪些特征表现出更强的关联证据。

不要承诺识别真正的“传染系数”。

Requirement 5：识别重大变化及可能的革命性音乐人

A. 官方要求

找出可能表示音乐演化中重大跃迁的特征，并识别网络中代表这些重大变化的音乐人。

必须同时处理**变化信号**和**音乐人**，只画一条拐弯的曲线不够。

B. 人话

> 哪些时期的音乐变化特别明显？哪些音乐人既做出了不同的东西，又与后来的变化存在联系？

C. 具体工作

1. 建立整体或流派的时间特征；
2. 定义“变化明显”；
3. 检查变化是否只是样本人数、作品数量或流派构成变了；
4. 在对应时期筛选有作品、有网络联系的音乐人；
5. 比较其新颖性、后续关联和网络地位。

D. 模型选择

简单方案：

- 相邻时期特征差；
- 与此前波动相比，是否出现异常大变化；
- 对候选人分别展示“早期不同”和“后来有人接近”的证据。

进阶方案：

- **Change-Point Detection**：寻找一条时间序列中，平均水平或趋势结构发生变化的位置；
- 用分段模型比较“整段一个规律”与“分成几段更合理”。

不需要先假定某个历史年份必然是转折点。

E. 最终展示

- 变化强度曲线；
- 候选变化区间；
- 变化前后特征分布；
- 革命性音乐人候选表及证据；
- 候选人在网络中的位置。

F. 难点

“特别不同”不等于“革命性”。

一个音乐人的风格很异常，但没有后续关联，可能只是独特；一个人很有名，但没有体现明显的新变化，也不能仅凭中心性称为革命者。

还要避免把录音版本、采样结构变化当成音乐史上的革命。

Requirement 6：深入研究一个流派的演化与动态影响者

A. 官方要求

分析一个流派随时间发生的音乐影响过程，提出识别动态影响者的指标，并解释流派或音乐人的变化。

B. 人话

> 选一个流派，讲清楚它怎么变、哪些音乐人在哪些时期与变化更相关，而不是只给一个全时期固定排名。

C. 具体工作

1. 根据数据覆盖选择一个流派；
2. 构建音乐人—时期和流派—时期特征；
3. 分析不同出道年代的追随者与前辈的关系；
4. 比较候选影响者的作品轨迹与其余流派成员；
5. 区分新成员进入与原有成员变化。

D. 模型选择

简单方案：

- 年代特征轨迹；
- 按追随者出道年代划分的关系统计；
- 候选人和流派其余成员的变化对照。

进阶方案：

- 有足够记录时，分析影响者较早风格与追随者之后风格的滞后关联；
- 增加固定效应回归，控制音乐人长期差异和各时期共同变化。

“固定效应”可以简单理解为：先扣掉某人一贯如此、某个年代大家都如此的部分，再看剩下的变化是否相关。

E. 最终展示

- 一个流派的时间故事；
- 音乐人—时期覆盖图；
- 流派特征曲线；
- 候选动态影响者的分时期指标；
- 一个清晰的子网络案例。

F. 难点

- 没有边形成日期；
- 很多音乐人只有少量作品或很短的时间跨度；
- 音乐人可能一直影响别人，但不再有新发行作品；
- 固定网络上的分年代统计，不能称为真实历史网络快照。

Requirement 7：说明音乐的文化影响，或讨论社会、政治、技术变化

A. 官方要求

原文给了两个方向：

1. 你们的工作怎样表达音乐在时间或情境中的文化影响；
2. **或者**，怎样在网络中识别社会、政治或技术变化的影响。

“Alternatively” 很关键：**题目并没有要求必须识别互联网或某场政治事件的因果效应。**

B. 人话

> 前面的数学结果，最终能帮助我们理解什么文化现象？这些数字能说什么，不能说什么？

C. 具体工作

在严格只用四个文件的条件下，建议走第一个方向：

- 哪些流派与后续世代存在持续联系；
- 哪些影响跨越了流派边界；
- 一些风格是否在后续作品中持续出现；
- 样本中是否出现风格趋同或分化。

D. 模型选择

简单方案：

- 复用跨流派联系、跨年代联系和风格轨迹；
- 加上一段有证据约束的文化解释。

进阶方案：

- 分析追随者流派构成的多样性；
- 对不同出道群体的跨流派联系进行比较。

这里不必另建一个“历史事件模型”。

E. 最终展示

- 跨流派 / 跨年代联系图；
- 与一个具体案例结合的解释；
- 明确列出无法观察的文化维度。

F. 难点

文件没有：

- 受众或粉丝行为；
- 地理位置；
- 社会态度；
- 政治事件变量；
- 互联网普及率；
- 历史传播媒介使用数据。

因此不能凭音乐曲线在某年变了，就声称某事件造成了变化；也不能把流派标签直接当成国家、民族或地域文化。

七项之外：必须提交给 ICM Society 的一页说明

这份说明要解释：

- 你们的方法有什么价值；
- 当前样本限制如何影响结论；
- 如果有更多、更丰富的数据，方法会如何改变；
- 推荐进一步研究什么。

这正好可以承接 Requirement 7 和数据限制，但它是独立的交付要求。

四、四个数据文件到底提供了什么

以下统计均来自本轮实际读取，**是原始文件、清洗前口径**。它们是数据审计结果，不是已经完成的建模结果。

1. 整体清单

文件	行数 × 列数	一行代表什么	主要用途
`influence_data.csv`	42,770 × 8	一条影响者—追随者关系	网络、流派标签、职业起始年代
`full_music_data.csv`	98,340 × 19	一条歌曲 / 音轨记录	特征聚合、音乐人和流派的时间分析
`data_by_artist.csv`	5,854 × 16	一个艺术家 ID 的汇总记录	静态风格表示与对照
`data_by_year.csv`	100 × 14	一个年份的汇总记录	全局时间背景与辅助核验

一个重要区别：官方背景写影响数据涉及 5,854 位音乐人，但实际影响表两端合并只有 5,603 个不同 ID。5,854 是当前艺术家汇总表的行数。建模要以实际数据为准。

2. 影响关系文件

对应文件：

[来源 3] influence_data.csv

八列分成两组，影响者和追随者各有：

- ID；
- 名称；
- 主流派；
- 职业开始年代。

实际读取时 ID 和年代是整数，名称与流派是字符串。**ID 应当作为标识符，不作为数值特征。**

检查结果：

- 42,770 条关系；
- 5,603 个不同音乐人 ID；
- 20 种流派标签，其中包含 `Unknown`；
- 没有普通缺失值；
- 没有完全重复行；

- 没有重复的有向 ID 配对；
- 没有自己影响自己的边；
- 主流派和起始年代在同一 ID 下是一致的；
- **3 个 ID 对应不一致的名称。**

具体冲突为：

ID	文件中出现的不同名称
893383	The Muffs；The Kills
303506	Usher；Day26
957340	Helloween；Nightwish

不能直接把这些当成合法别名，也不能凭记忆修正。应记录为身份冲突；主分析可以排除相关节点或边，并比较保留时结果是否变化。

流派规模非常不均衡：

- Pop/Rock：2,808 人；
- R&B：677 人，原始标签写作 `R&B;`；
- Jazz：406 人；
- Country：403 人；
- Blues：101 人；
- Classical：28 人；
- Children's：4 人；
- Unknown：3 人。

因此，“全体音乐人的平均结果”很容易主要反映 Pop/Rock。

时间顺序检查：

影响者出道年代与追随者相比	边数
更早	33,560
相同	8,477
更晚	733

这 733 条不能直接判为错误。后出道者可能影响仍在活动的前辈。

但它们说明：

> “影响者一定更早出道”“边在追随者出道时就形成”都不是可以无条件使用的事实。

这个文件最直接支持 R1，并给 R2—R7 提供标签与关系。它不能告诉我们影响强度、影响发生日期、影响者何时停止活动。

---

3. 歌曲明细文件

对应文件：

[来源 4] full_music_data.csv

实际列名需要注意：这里是 `artist_names` 和 `artists_id`，不是汇总表中的单数形式。

主要字段可以分成五组：

变量组	字段	数据类型与含义
音乐人信息	`artist_names`, `artists_id`	字符串保存的列表，可能有多位音乐人
0—1 连续特征	danceability、energy、valence、acousticness、instrumentalness、liveness、speechiness	浮点数，含义由题目词汇表定义
其他连续特征	tempo、loudness、duration_ms	BPM、dB、毫秒
离散或状态变量	mode、key、explicit	大小调、调性编码、显式歌词标记
时间与说明	popularity、year、release_date、song_title (censored)	流行度、发行年份、日期、经过过滤的歌名

检查结果：

- 没有普通缺失值或空字符串；
- **189 条完全重复记录**；
- **4,410 条多人合作记录**；
- 每条的音乐人名称列表与 ID 列表长度一致；
- 单条最多列出 28 位音乐人；
- 列表展开后共 **103,487 条歌曲—音乐人署名记录**；
- 涉及 **5,810 个不同 ID**；
- 同一条记录内部没有重复艺术家 ID；
- 没有唯一 track ID，不能可靠判断所有同名、重录或再发行版本。

完全重复记录可以在分析副本中去重；但“同名歌曲”不能一律去重。

时间字段并不整齐：

- `year` 范围是 1921—2020；
- 实际只有 98 个年份，缺少 1922、1923；
- 有的年份只有 1—2 首记录；
- `release_date` 混合了：
  - 只有年份；
  - 年—月；
  - 月 / 日 / 年；
- 发现 **4 条** `release_date` **中的年份与** `year` **不一致**，例如 `year=1927`，日期却写作 `1/1/2027`。

不能强行把只有年份的记录都解释成准确的 1 月 1 日。对本项目，优先使用经核验的年度或年代粒度，比假装拥有精确日期更合理。

数值异常或边界记录：

- `tempo=0`：26 条；
- `loudness>0`：15 条；
- 时长小于 30 秒：29 条；
- 时长超过 20 分钟：83 条；
- 最长约 63.6 分钟。

这些不是全部都应删除。很长的作品、短片段、特殊响度可能是真实记录；`tempo=0` 则可能涉及无法识别节拍等情况。应先标记，再根据用途处理。

与职业开始年代的冲突：

直接按 ID 连到网络后，有：

- 2,756 条歌曲—音乐人署名记录；
- 对应 2,718 条不同歌曲记录；
- 涉及 288 个音乐人；

其 `year` 早于该音乐人的 `active_start`。

这说明时间分析必须做敏感性检查。不能擅自解释为“全部都是再发行”或“全部都是错误”。

纵向分析的覆盖也有限：

按原始歌曲年份分年代：

- 2,728 个音乐人只在一个年代有记录；

- 3,082 个跨至少两个年代；
- 1,382 个跨至少三个年代；
- 1,187 个音乐人在歌曲明细中只有一条署名记录。

所以，不能给所有音乐人都拟合一条可靠的“风格演化路径”。

这个文件是 R2—R6 的关键；但它不提供歌词、原始音频、创作时间或真实历史播放量。

---

4. 艺术家汇总文件

对应文件：

[来源 5] data_by_artist.csv

基本结构：

- 5,854 行、16 列；
- `artist_id` 唯一；
- 有音乐人名称、音乐特征、`popularity` 和 `count`；
- 没有年份；
- 没有主流派，需要从影响表关联；
- 没有 `explicit`；
- 没有普通空值或完全重复行。

不能默认它就是当前歌曲明细的精确 groupby 结果。

核验发现：

- `count` 总和为 **198,733**；
- 当前歌曲明细展开署名后只有 **103,487** 条；
- 在有歌曲记录的 5,810 个 ID 中，只有 241 个的 `count` 与直接展开后的记录数一致；
- 比较 11 个连续特征，在绝对误差 10^{-5} 的检查口径下，3,006 个音乐人的全部这些均值能与当前明细直接聚合对上，其余不能全部对上。

因此：

> 这张表可以作为题目提供的独立汇总输入，但不能声称所有汇总值都由你们当前拿到的歌曲明细重算得到。

目前无法仅凭四个文件确定差异的完整来源，不能猜测是哪个外部版本造成的。

另外：

- 有 41 组名称对应多个 ID，共涉及 85 行；
- `mode`、`key` 仍是整数编码；
- 不能把这些编码当普通连续均值来解释；
- 没有时间维度，不能用全时期均值代替某个早期年代的风格。

---

5. 年度汇总文件

对应文件：

[来源 6] data_by_year.csv

结构与检查：

- 100 行、14 列；
- 1921—2020，每年一行；
- 年份唯一；
- 没有空值或重复行；
- 没有艺术家 ID、流派、每年样本量；
- `mode` 所有年份都是 1；
- `key` 是整数编码。

更关键的是：

- 它包含歌曲明细没有的 1922、1923 年；
- 对共有连续特征检查，无法将它完整复原为当前明细的逐年均值。

因此不建议把这张表的整体趋势，直接与从歌曲明细算出的某个音乐人轨迹拼在一起，再假定两者来自同一统计样本。

适合用途：

- 作为题目提供的整体时间背景；
- 与自己从明细重算的趋势做方向性对照；
- 检查结论是否对汇总来源敏感。

不适合用途：

- 给某个流派画年度趋势；
- 给某个音乐人补充缺失年份；
- 根据它计算年度标准误；

- 代表当时真实市场流行度。

尤其是 `popularity`：官方定义强调播放量及播放的近期性。**按歌曲发行年份分组的 popularity，不等于该年份当时的流行度。**

---

6. 四张表能不能正确关联

直接按原始 ID 的关联结果如下：

关联情况	数量
网络音乐人	5,603
网络中可在艺术家汇总表找到的 ID	5,602
网络中可在歌曲明细找到的 ID	5,560
汇总表有、网络没有的 ID	252
汇总表有、歌曲明细没有的 ID	44
关系两端都能连到艺术家汇总的边	42,752
关系两端都能连到歌曲明细的边	41,556

网络中唯一没有艺术家汇总记录的 ID 是 `477787`，名称为 The New Pornographers。

这里的"能连上"只是 ID 层面的初步覆盖，还没有排除前述身份冲突或时间异常。

Oasis 是一个非常有教学意义的例子：

- 影响表中，Oasis 是 `393345`；
- 艺术家汇总中，`393345` 和 `1426593` 都叫 Oasis，所检查的汇总特征一致；
- 歌曲明细中，Oasis 的记录使用 `1426593`。

这提供了一个**内部交叉映射候选**，但不能由此制定"同名就合并"的规则，因为文件里还有别的名称重复与身份冲突。

我的建议是：

- 主结果先使用可审计的直接 ID 关联；
- 另建"候选 ID 映射表"，记录内部证据；
- 对证据充分的映射做一个扩展口径；
- 比较扩展前后结果；
- 无法确认的身份冲突不强行修复。

7. 我建议采用的数据口径

为了让整个项目可复现：

- **全网络分析**：基于影响表，保留与处理冲突的规则要明确；
- **主要风格与时间分析**：从歌曲明细统一构建音乐人特征及音乐人—时期特征；
- **艺术家汇总表**：做静态特征的对照版本，检查口径敏感性；
- **年度汇总表**：做整体趋势的辅助对照；
- 不把两张汇总表当成独立新样本扩大样本量；
- 不把全时期均值拿去填充历史时期的缺失特征。

这是比"挑一个最方便的表就一直用"稍多一点准备工作，但会让后面所有模块更稳。

五、统一框架应该怎样设计

Layer 1：被报告的 Influence Network

节点与边

$$A_{ij} = \begin{cases} 1 & \text{数据记录} i \text{影响了} j \\ 0 & \text{没有记录该方向的关系} \end{cases}$$

节点带上：

- ID；
- 名称及冲突标记；
- 主流派；
- 职业开始年代；
- 特征与时间数据是否可用。

初始网络不需要加权。 原始文件没有影响强度，二元关系是最忠实的起点。

可以采用下面的指标组合：

指标	它实际回答的问题	我的建议
Out-degree	有多少人被记录为受此人影响?	主指标，必须有清楚基线
In-degree	此人列出了多少影响来源?	描述来源广度，不当作其影响别人的能力

分摊后的追随者认可	考虑追随者有多少影响来源后，此人得到多少认可?	简洁、可解释
反向 PageRank	此人是否被后来也有结构地位的人认可?	合适的递归指标
Betweenness	此人是否处于很多连接路径上?	辅助解释桥梁角色
Eigenvector Centrality	与重要邻居连接是否使自己重要?	方向及有向图结构更难解释，非必需

一个简单的分摊指标是：

$$C_{\mathrm{i}} = \sum_{j:A_{\mathrm{ij}}=1} \frac{1}{k_j^{\mathrm{in}}}.$$

意思是：追随者 j 有多少位被记录的影响者，就把这一份认可分成多少份。

这是**模型中的信用分配规则**，不是实际心理影响强度。

PageRank 为什么要反向

如果原始边为 $i \to j$，通常的 PageRank 通过入边给节点分数。因此直接使用原方向，容易强调"受到重要来源指向的人"。

如果我们的问题是"谁被重要追随者认可"，就让追随者把分数传回前辈，也就是在反向图上计算。NetworkX 的官方定义也明确以入边结构计算 PageRank。NetworkX 官方说明

原始关系图的方向仍然是影响者 → 追随者。**只是在计算某个指标时反转，不是改写原始关系的含义。**

不建议一开始就用相似度给网络加权

因为 R4 正要检查网络关系与相似性是否对应。

如果先根据相似性强化某些边，再用这个加权网络证明音乐人很相似，论证就不独立了。

主分析先把两个层次分开。相似度加权网络最多作为后续扩展。

Layer 2：Musical Feature Representation 与 Similarity

第一步：决定哪些变量属于"风格"

建议主模型使用这 10 个连续特征：

- danceability；
- energy；
- valence；

- tempo；
- loudness；
- acousticness；
- instrumentalness；
- liveness；
- speechiness；
- duration_ms。

其中 duration 可以考虑取对数，降低极长作品的支配作用。

另行处理：

- `mode`：可以表示为某时期“大调作品比例”；
- `key`：不能把 C、C♯ 等编码直接当线性数轴距离；初版可以不纳入；
- `explicit`：可作为补充内容特征，但 0 包含“没有或未知”，解释要谨慎；
- `popularity`：主风格距离中排除；
- `year`、ID、count：不是风格特征。

“数据里有这个列”并不是把它放进相似度的理由。

第二步：歌曲怎样聚合到音乐人

先建立歌曲—音乐人关联表，再构建：

$$x_i = \text{音乐人} i \text{的整体特征向量},$$

$$x_{i,t} = \text{音乐人} i \text{在时期} t \text{的特征向量}.$$

初版可用均值，同时保留：

- 歌曲数量；
- 标准差或四分位距；
- 覆盖年份；
- 是否只有一首歌；
- 是否含合作作品；
- 时间异常比例。

均值会损失什么？

一个人一半作品非常安静、一半非常激烈，均值可能与一个始终温和的人相同。

因此：

- 均值适合建立可解释的基础表示；
- 分布差异是有价值的扩展；
- 不应声称均值完整代表音乐人的风格。

合作作品可以归给所有署名者，但比较流派总体时要避免把一首多人合作曲无限放大。可对同曲 m 位署名者分配各 $\frac{1}{m}$ 的权重，并把“只取第一署名者”作为敏感性版本。两者都是分析规则，不是实际贡献比例。

第三步：标准化

原始特征单位不同，时长可能几十万毫秒，energy 只有 0—1。

直接算距离，结果会被单位最大的变量支配。

可以使用：

$$z_{ik} = \frac{x_{ik} - \mu_k}{s_k}.$$

即把每个特征改成“相对参考样本平均水平偏离多少个标准差”。

时间分析中应固定同一套尺度，不能每个年代各自重新标准化，否则“整个年代都变得更有能量”的变化可能被消掉。

如果做真正的时间留出核验，标准化参数只能从训练时期确定。

第四步：选择主相似性

我更推荐：

$$d_{ij} = \sqrt{\frac{1}{p}\sum_{k=1}^{p}\left(z_{ik} - z_{jk}\right)^2}, \qquad S_{ij} = \frac{1}{1 + d_{ij}}.$$

它的解释直接：

> 每个标准化音乐特征都比较一下，总体差得越小，音乐人越相似。

Cosine Similarity 可以用，但要理解它测量什么

Cosine 比较的是方向，而不是数值距离。

对于中心化后的向量，它更接近：

> 两个人相对于平均音乐风格的偏离方向是否相似?

这和 TF-IDF 中“词频构成方向相似”有相通之处，但不是完全相同的对象。

还要处理：

- 接近零向量时角度不稳定；
- 中心化后的 Cosine 可以为负；
- 两个风格向量方向相同，但偏离幅度很不一样。

所以我会用 Euclidean 作主口径，Cosine 作敏感性分析，而不是因为你熟悉 Cosine 就强制把它放在主模型里。

TF-IDF 不需要迁移

四个文件没有适合建立音乐内容词袋的歌词或长文本。

歌名既短又经过过滤，不值得为了使用 TF-IDF 把它当主要音乐内容。

你真正可以迁移的是：

- 对象表示；
- 标准化；
- 相似性矩阵；
- Top-K 邻居；
- 对照组构建；
- 时间对齐与防止信息泄漏。

Top-K Peer Network 可以作为辅助图

它回答：

> 在数值音乐特征上，谁是某音乐人最接近的风格邻居?

但它不是官方 Influence Network。

Top-K 导致的有向性可能只是“我的前 K 名有你，你的前 K 名没有我”，不表示影响方向。可以用互为近邻构建无向风格网络，并研究它与影响网络的重合程度。

初版不一定需要这张额外网络。先完成相似性比较，更划算。

Layer 3：Temporal Analysis

时间层最重要的是分清三个时钟：

时间	文件是否有	可以怎么用
音乐人职业开始年代	有	划分音乐人群体、控制年代差异
音轨发行年份	有，但有异常和版本问题	构建观测作品的时间特征
影响关系形成时间	没有	不能直接构建真实历史边时间序列

可以可靠推进的内容

- 样本中的流派特征怎样随年代变化；
- 不同年代开始职业生涯的追随者，连接了哪些前辈；
- 候选影响者较早作品与后续作品是否有关联；
- 重大变化信号对时间分箱是否稳定；
- 流派变化来自成员更替，还是持续出现的音乐人也在改变。

必须谨慎命名的内容

可以建立“截至某年代已出道音乐人的回顾性诱导子图”，但它只表示：

> 在最终记录的关系中，挑出两端都已出道的那些关系。

它不表示这些边当时已经存在。

更稳妥的 R6 指标之一，是：

> 某音乐人被不同出道年代的追随者记录为影响者的比例。

这衡量**影响关联的跨世代分布**，不需要凭空给边赋日期。

从 Connected-Firm Momentum 可以迁移什么

你可以定义一个音乐人的“前辈风格暴露”：

$$E_{\mathrm{i,t-1}} = \frac{1}{|\mathcal{P}_{\mathrm{i,t-1}}|} \sum_{j \in \mathcal{P}_{\mathrm{i,t-1}}} x_{\mathrm{j,t-1}},$$

其中 $\mathcal{P}_{\mathrm{i,t-1}}$ 是该音乐人记录中的影响者，且这些影响者在此前时期有可用作品。

这与“连接企业的过去信号”在计算上很相似。

但是有一个关键区别：

> 公司研究中，你可能知道某条关系在某日已存在；这里的影响边来自最终汇总关系，未必在 $t-1$ 已经形成。

因此这种设计应称为**基于回顾性网络的滞后风格关联**。即使只用了过去作品，也不能自动升级为没有前视问题的历史预测实验。

Layer 4：必要的专项模块

在共享框架上，我建议只增加三个必要部分：

1. **关系核验与特征关联模块**：主要回答 R4；
2. **重大变化与候选音乐人模块**：主要回答 R5；
3. **文化解释与证据边界模块**：主要回答 R7。

R6 是时间层的深入案例；不一定需要再增加一个复杂算法。

六、Requirement–Model Mapping

这里的难度是针对你们当前数据与建议方案的相对判断：1 最容易，5 最难，不是统计测算。

Requirement	核心问题	所需数据	核心模型	统一框架分类	额外分析	主要输出	难度
R1	谁在影响网络中重要?	影响表	有向图、出度、分摊指标、反向 PageRank	**A**	子网络选择与解释	子网络图、指标表	2
R2	同流派音乐人是否更相似?	歌曲 / 艺术家特征＋流派	标准化距离、相似性比较	**A**	配对抽样与不确定性	分布图、相似性热力图	2–3
R3	流派如何关联、区别和变化?	网络、特征、年份	流派影响矩阵、相似矩阵、时间轨迹	**A**	规模校正、样本构成检查	双热力图、特征趋势	3
R4	记录关系是否有作品特征支持?	边＋音乐人或时期特征	相似性差异	**B**	匹配对照、重排检验、可选回归	对照结果、特征关联排序	5
R5	重大变化在哪里，谁可能参与引领?	时间特征＋网络	特征变化、网络地位	**B**	变化检测、新颖性与后续关联	变化区间、候选人证据	4
R6	一个流派怎样演化?	单流派的关系与时期特征	分时期风格与跨世代关系	**B**	覆盖筛选、可选滞后模型	流派案例、动态指标	4

R7	这些结果表达什么文化联系?	前面各模块结果	跨流派、跨世代结构	**C**	独立解释与证据边界	文化讨论、进一步研究建议	3；若追求事件因果则超出数据能力

分类理由：

- **A**：主要是直接读取统一框架已经产出的网络、特征和时间结果；
- **B**：基础信息共用，但必须新增比较设计或识别规则；
- **C**：需要把数学结果转成有约束的文化解释，无法由某个网络分数自动生成。

七项可以归纳成四个核心研究任务

1. **结构影响**：R1；
2. **风格与流派关系**：R2、R3；
3. **关系核验、演变与重大变化**：R4、R5、R6；
4. **文化含义与研究边界**：R7，以及给 ICM Society 的说明。

可以共享的数据工程

- 所有要求共享身份核验、流派标签和覆盖表；
- R2—R6 共享音乐特征处理；
- R3、R5、R6 共享音乐人—时期与流派—时期表；
- R1、R3—R7 共享原始关系图；
- R2—R6 共享相似性定义。

哪些需要额外数学方法

- R4 需要对照或统计核验，单纯距离计算不够；
- R5 需要明确的“大变化”判定规则，单纯画图不够；
- R6 需要时间组织和动态指标，但不强制需要回归；
- R7 不一定需要新数学模型。

不能可靠支持的分析

- 真实边形成、消失和传播速度；
- 个体层面的严格因果影响；
- 某政治事件、互联网普及对音乐的净因果效应；
- 某音乐人当年的真实流行度；
- 整个世界音乐市场的代表性结论。

这些限制不意味着项目无法完成。关键是**用数据能支持的证据回答问题，而不是把题目的自然语言当成必须证明的因果命题**。

七、两篇 Outstanding Winner papers 给我们的具体启发

第一篇：《Measure of Influence and Similarity in Dynamic Networks of Musicians》

对应文件：

[来源 7] D21018555.pdf

这篇最值得借鉴的是**组织方式**：它确实有一条统一主线。

主要方法与位置：

- 第 5—8 页：静态 / 动态网络、重新缩放的 PageRank；
- 第 8—9 页：加权 Cosine Similarity，用网络距离构造训练目标，再优化特征权重；
- 第 10—12 页：把相似性与时间衰减加入 PageRank，讨论影响与相似性的关系；
- 第 12—17 页：流派区别、革命性音乐人、Blues 时间案例；
- 第 17—19 页：参数敏感性与 GCN 补充试验；
- 第 21 页：给 ICM Society 的信。

它不是严格按七项逐章写，而是先建立通用指标，再应用到流派、革命和案例。

值得借鉴的地方

- 注意到老音乐人积累关系更多，跨年代排名可能不公平；
- 音乐人风格按年代表示，而不是全时期一个向量；
- 先建指标，再用案例解释；
- 比较某音乐人与流派趋势时，讨论排除该音乐人自身贡献，避免机械相似。

不建议照搬的地方

1. **边形成时间假设。**
   论文第 4 页明确假设，追随者一开始活跃，关系就建立。这是论文的假设，不是数据事实。
2. **用网络训练相似性，再核验网络。**
   如果距离本身已经被训练得贴近网络结构，再拿它说明关系中的音乐人更像，会缺少独立验证。
3. **时间衰减参数。**
   “旧作品影响几何衰减”可以做假设，但文件本身没有直接估计这个衰减速度的证据。
4. **GCN。**
   图卷积神经网络是在节点特征和邻居信息之间反复混合、学习表示。它会增加训练、解释和验证成本，当前题目没有必须用它才能回答的核心问题。

5. **关于回归不能用于动态结构的表述。**
   这不应成为我们排除回归的理由；是否适用取决于具体数据结构与识别目标。

适合你们的替代版本是：

> 静态结构指标＋分年代风格表示＋独立定义的距离＋匹配对照＋一个流派案例。

第二篇：《Mining the Influence of Music Based on Social Network Analysis and Statistical Methods》

对应文件：

[来源 8] D21060286.pdf

这篇更适合当**要求覆盖清单**，基本按 Problem 1—7 对应七项要求。

主要方法：

- R1，第 5—9 页：Betweenness、Eigenvector、三层可达范围、Follower Loyalty、流派多样性，使用熵权法合成影响分数；
- R2，第 9—11 页：Factor Analysis，提取三个潜在维度，并构建相似性比较；
- R3，第 11—15 页：流派关系、特征分布和时间变化；
- R4，第 15—16 页：关系配对与随机配对的相关性比较；
- R5，第 16—18 页：Moving Average、Bollinger Bands、变化趋势相关；
- R6，第 18—20 页：影响分数与 popularity 结合，选择动态影响者；
- R7，第 20—21 页：文化和互联网的讨论；
- 第 21—22 页：窗口和阈值敏感性。

值得借鉴的地方

- 要求覆盖非常清楚；
- 有“关系组 versus 随机组”的核验意识；
- 用特征分布而不只是排名讲流派差异；
- 做窗口和阈值敏感性；
- 很多方法本科阶段可以实现。

需要改进、不能照搬的地方

1. **随机对照过于宽泛。**
   更好的比较应控制流派与年代，避免只是比较“同类人”和“完全不同的人”。

2. **相关性结论说得过强。**
   第 15—16 页将统计关联解释为确实受到影响，我们不应照搬这种因果措辞。
3. **历史 popularity 的解释。**
   按作品发行年份分组的当前 popularity 不能当成当时流行度。
4. **Bollinger Bands 不是天然的置信区间。**
   滚动均值加减若干标准差，首先是波动参考带；没有额外分布和依赖假设，不自动拥有某个统计置信水平。
5. **指标合成不一定更客观。**
   熵权法依据指标分布差异给权重，但“更分散”不等于“更能表示音乐影响”。
6. **个别定义与公式存在不一致。**
   第 7 页的流派多样性文字说要数不同流派，显示的公式却是在统计与源节点同流派的成员。不能直接复制公式。

这篇的本科替代方案可以是：

> 保留分模块结构，减少综合评分，改进对照组，谨慎处理时间与因果解释。

关于“关系相似”和“真实传播”难以区分，这也是网络研究中的一般问题：人可能因为本来相似而建立关系，也可能因关系而变得相似。只靠观察数据，两者经常混杂。Shalizi 与 Thomas 的原始研究

本轮外部核对仅用于方法定义与解释边界，没有引入任何外部音乐数据。

八、两套可执行方案

方案 A：Simple but Strong——我建议作为正式主方案

核心思想：

> 保留两个独立证据层，再用时间与对照把它们联系起来。

模块	采用的方法	覆盖要求
网络	二元有向图、出度、分摊认可、反向 PageRank；一个子网	R1
风格	统一特征处理、标准化 Euclidean；	R2

	Cosine 作替代检查	
流派	影响矩阵、相似矩阵、特征分布和年代曲线	R3
核验	同流派 / 相近年代的匹配对照；特征层面的差异和重排检查	R4
变化	分时期特征变化；候选人的新颖性和后续关联	R5
深入案例	一个覆盖较好的流派，分年代关系和风格轨迹	R6
文化解释	跨流派、跨世代联系与边界讨论	R7

优点

- 每个输入、公式和输出都容易讲清楚；
- 共享的数据处理多；
- 无需深度学习或大规模训练；
- 验证与敏感性分析自然；
- 能控制在 25 页和 8 张 Slides 内。

主要风险

- 匹配后的可用样本减少；
- 部分关系没有明显额外相似性；
- 变化候选人不一定有完整时间记录；
- 数据处理仍需认真做。

第二点不是项目失败。**“在控制流派和年代后，证据减弱”也是有效发现**，只要方法合理、解释清楚。

单流派案例怎么选

我建议先比较：

- **Country**：网络中 403 人，明细直接关联到 401 人；
- **Blues**：101 人，明细能直接关联到这 101 人；
- Pop/Rock：覆盖多，但范围大、异质性强，容易把案例做散。

我的初步倾向是：

- 想兼顾样本与可控性，先审查 Country；
- 想用更小网络讲清楚机制，审查 Blues；
- 最终依据连续时期覆盖、作品量和异常比例决定，不能只按音乐史知名度决定。

方案 B：More Ambitious——在 A 完整后只加有价值的深度

我建议优先考虑以下两项，而不是全部堆上去。

扩展一：滞后风格关联模型

研究：

> 在控制音乐人自身过去风格与同年代共同变化后，前辈的过去风格是否还能解释追随者之后的风格?

可以考虑：

$$x_{\mathrm{i,t,k}} = \alpha_{\mathrm{i}} + \delta_{\mathrm{t}} + \varphi x_{\mathrm{i,t-1,k}} + \beta E_{\mathrm{i,t-1,k}} + \varepsilon_{\mathrm{i,t,k}}\,.$$

其中：

- $x_{\mathrm{i,t,k}}$：音乐人 i 在时期 t 的某个特征；
- α_{i}：音乐人一贯的差异；
- δ_{t}：全体共同的时期变化；
- $E_{\mathrm{i,t-1,k}}$：前辈此前的特征平均值。

这只是候选规格，不意味着现在就应估计。需要先检查面板长度、缺失、短面板偏误和网络依赖。

它支持 R4、R6，但仍是关联模型。 最终汇总网络没有历史边时间，固定效应也无法自动解决这个问题。

扩展二：更正式的变化检测

比较不同分段数、不同最短区间长度，识别稳定的变化区间；再检查：

- 结果是否在主要原始特征中也可见；
- 是否由流派构成变化驱动；
- 是否在替代聚合口径下保留。

支持 R5，也加强 R3、R6。

可选第三项：风格分布，而不只是均值

对少数重点音乐人比较作品分布，避免“均值一样，风格结构完全不同”。

这有助于解释相似性指标的局限，但初版不必对所有人计算复杂分布距离。

方案 B 的优点

- 更接近你熟悉的 Quant 研究；
- 能提出更精确的研究问题；
- 时间逻辑和验证更有深度。

主要风险

- 只有较少音乐人拥有足够长的时间记录；
- 需要解释模型假设与标准误；
- 容易把回顾性关系误写成历史可观测关系；
- 加模型后可能挤占完整回答七项要求的篇幅。

我的选择是：先完成 A，再决定是否增加一个 B 模块。 优先考虑正式变化检测；面板模型是否值得做，取决于数据覆盖审查结果。

九、Validation 和 Sensitivity Analysis 应该怎样安排

这部分最好从一开始设计，而不是最后随便改几个参数。

Validation：检查我们的结果是否有可信依据

层面	应做的验证
数据关联	ID 覆盖、冲突记录、join 后行数是否意外膨胀
网络	手工核对几个已记录关系；检查方向与指标含义
相似性	不同距离是否给出相近的主要结论；检查具体近邻是否由单一变量支配
流派比较	不同流派平衡抽样；控制年代；排除自配对
影响核验	匹配对照、限制条件下的重排；避免把共享节点配对当独立样本
时间分析	最低样本量、时间异常筛选、留出区间、成员构成检查
重大变化	不同窗口下区间是否稳定；候选音乐人是否有足够作品与后续联系

对网络配对，最简单的独立样本 t 检验通常不足以处理共享音乐人。应按音乐人组织重抽样，或使用适合关系数据的置换设计；进阶回归再考虑双端聚类等方法。

Sensitivity：检查结论是否由人为选择决定

建议优先检查这些：

1. Euclidean 与 Cosine；
2. 特征是否包含 duration、liveness 等较特殊变量；
3. 原始均值与稳健聚合；
4. 合作作品全署名、分摊、第一署名口径；
5. 原始 ID 与经内部证据审查的映射版本；
6. 是否排除身份冲突、时间冲突；
7. 歌曲加权与音乐人等权；
8. 年度、五年、年代分组；
9. 最少作品数与最少时期数；
0. 变化窗口、阈值或分段惩罚。

不必每个选择都做几十组实验。重点是找出**会改变解释的关键选择**。

例如：

- 如果改距离就换了一半“革命者”，排名不稳；
- 如果排除一个大产量音乐人，流派趋势消失，应当报告；
- 如果只在完全不匹配的随机对照下显著，不能声称强支持。

十、真正开始时的执行顺序

我会按依赖关系这样安排。下面是实施规划，本轮没有运行这些完整模型。

阶段	具体做什么	Python 工具	预期产出与复用	完成标准
1. 规格确认	将七项要求与一页说明拆成清单	无需专门库	Requirement 检查表，后续写作复用	每项都有问题、方法、图表和限制
2. 数据审计与口径	ID、列表、重复、日期、汇总差异、合作作品规则	pandas、numpy、ast	节点表、关系表、歌曲关联表、异常清单	所有 join 覆盖与排除原因能解释
3. 基础网络	建图、基本指标、候选子网	NetworkX	全网结构和影响指标，R1 / 3—7 复用	方向正确；小例子可手算核对
4. 统一特征表示	选特征、变换、标准化、聚合、记录样本量	pandas、numpy、scikit-learn	音乐人和音乐人—时期特征	没有把类别编码当连续变量；时间尺度一致
5. 相似性与流派	配对距离、流派内外比较、流派影响矩阵	scipy、scikit-learn、seaborn	R2 / R3 基线，后续核验复用	主要结论不由规模差异或单列支配
6. 影响关系核验	匹配对照、逐特征比	pandas、numpy、	R4 证据表	对照有共同支持；依

	较、重排设计	scipy；可选 statsmodels		赖与多重比较被处理
7. 时间、变化与流派案例	覆盖筛选、时间轨迹、变化信号、候选人物	pandas、numpy、matplotlib；可选 ruptures	R3 / R5 / R6 共用时间结果	未把边时间、发行时间和出道年代混用
8. 整合验证与敏感性	对关键选择运行预先定义的替代版本	前述库	稳健性表、限制清单	能区分稳定发现和不稳定发现
9. 解释与交付组织	R7、一页说明、报告图表链、Slides、Q&A	后续再选写作工具	从问题到证据的完整故事	七项全部有回答；每个数字可复现；成员都能解释

第 4 阶段构建好音乐人—时期特征后，可以先做覆盖审查来选择案例；不必等所有静态结果完成才发现时间数据不够。

代码组织也应围绕共享产物：

- 一套清洗入口；
- 一套特征工程；
- 一套网络结果；
- 各 Requirements 读取这些结果。

不要七个人或七个脚本分别清洗出七种音乐人名单。

如果今天正式开始，最先打开哪个文件？

先打开 `influence_data.csv` 。

先看六个关键列：

- `influencer_id` ；
- `follower_id` ；
- 两侧 `main_genre` ；
- 两侧 `active_start` 。

名称用于人工核对，但不要作为默认 Join Key。

最先做的三件事：

第一件：建立节点与关系的数据契约。

明确：

- 一行是一条什么关系；
- 箭头方向；
- ID 如何唯一识别音乐人；

- 发现冲突时怎么标记；
- 年代不等于边时间。

产出应是一张节点表和一张有向边表，而不是先画全网“毛线团”。

第二件：做跨文件 ID 覆盖表。

依次连接艺术家汇总和歌曲明细，回答：

- 哪些节点能做静态风格比较；
- 哪些能做时间比较；
- 哪些名称 / ID 有冲突；
- 每一步保留多少节点和边。

第三件：建立一个很小、可以手工检查的数据链。

例如 The Beatles → David Bowie：

- 关系能否找到；
- 两端 ID 是否一致；
- 歌曲列表能否正确展开；
- 年份和作品量是否合理；
- 能否形成每人的年代特征表。

这三件事比今天就算一整张 Cosine Matrix 更能决定后面是否顺利。

十一、我建议的最终项目结构

1. 最自然的数学主线

不是“用各种算法分析音乐”，而是：

> **被报告的音乐影响关系，在多大程度上对应可观测风格相似性？这种对应如何随流派与年代变化，又能帮助我们识别哪些重大风格变化及相关音乐人？**

这个问题可以自然串起七项要求。

2. 哪些要求容易，哪些最难

- **较容易**：R1 的基础网络、R2 的相似性基线；
- **中等**：R3 的流派汇总与区别；
- **最需要统计判断**：R4；
- **最需要时间口径与定义**：R5、R6；
- **最需要克制解释**：R7。

难点不主要在 Python 代码量，而在你能否回答：

- 为什么这样定义影响力？
- 为什么这个对照公平？
- 为什么这算变化，而不是抽样结构变了？
- 为什么你称它为关联，而不是因果？
- 换一种合理选择，结论还在不在？

3. 你现有 Quant RA 经验可以直接迁移的部分

- ID 对齐与关系表构建；
- 特征工程和标准化；
- Cosine / 距离矩阵；
- Top-K 邻居与稀疏关系；
- 分组与时期聚合；
- Peer Exposure 的构造；
- 控制变量、固定效应与匹配思路；
- 数据泄漏检查；
- 稳健性、样本覆盖和可复现研究。

需要重新适应的部分

- 没有收益率式的明确结果变量；
- 没有可靠的关系形成日期；
- 音乐相似性本身需要定义和验证；
- 流派是粗标签；
- 音乐风格变化与社会影响之间隔着很多未观测环节。

4. 值得提前学习的新方法

优先级从高到低：

1. 有向网络指标的方向和解释；

2. 配对 / 关系数据的依赖问题；
3. 匹配对照与受约束置换；
4. 变化检测的基本思想；
5. 时间聚合和样本构成变化；
6. 如果实施 B，再学习短面板与滞后模型的局限。

PCA 可以学，但不是必须。GNN 不在优先清单里。

5. 时间有限时，必须优先保证什么

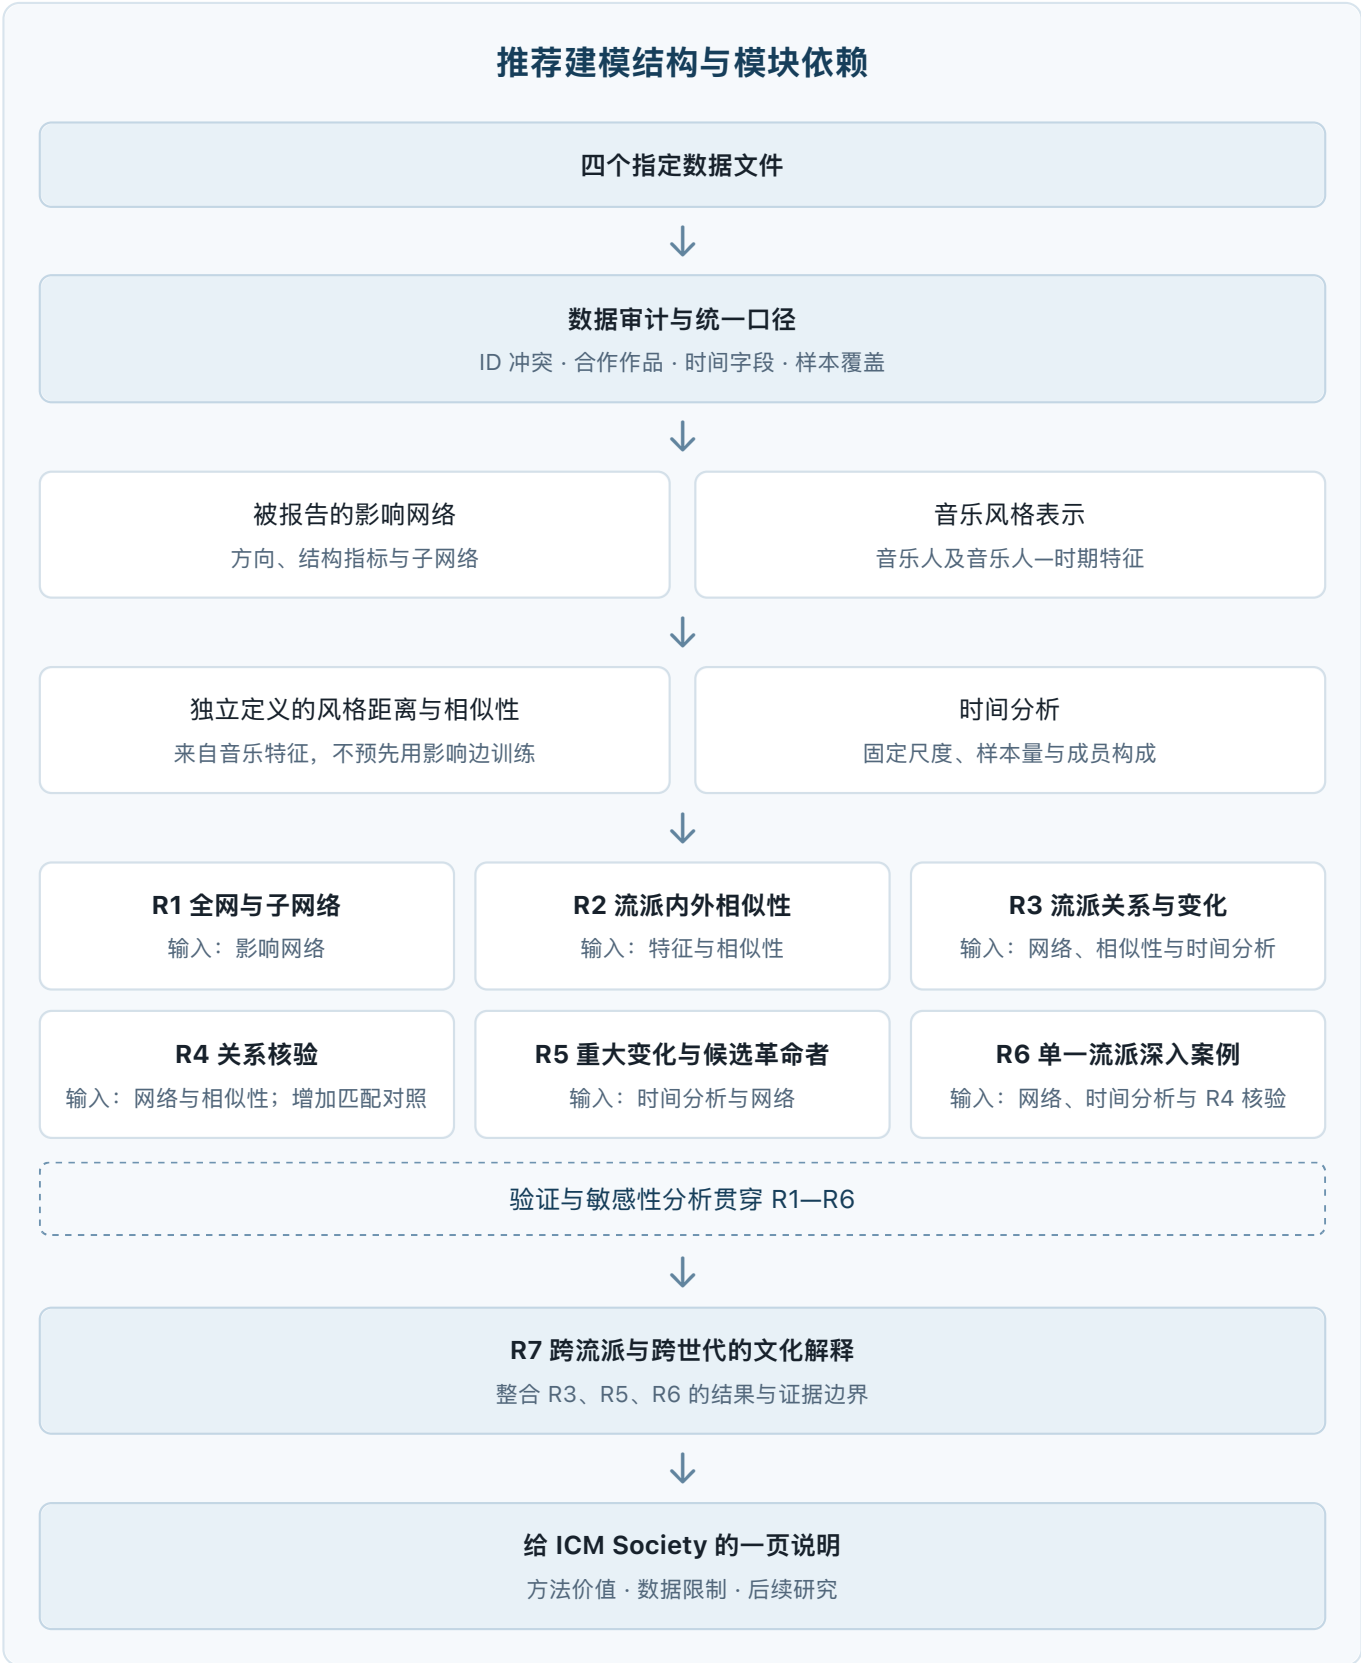
- 七项要求一个不漏；
- ID、时间和汇总口径明确；
- 一个解释得清楚的相似性定义；
- R4 有合理对照；
- R5 有明确变化定义和候选人证据；
- R6 有完整案例；
- 所有结论有对应图表、限制和复现路径。

不要在 R1 排名上调十种中心性，却没有时间完成 R4 的核验。

6. 哪些看起来高级、实际上可以避免

- 将 TF-IDF 强行用于数值音乐特征；
- GCN、GAT、复杂图嵌入；
- LSTM 或 Transformer 预测稀疏音乐人时间序列；
- 没有传播时间数据的 SIR、Hawkes 传播模型；
- 为了综合而综合的熵权 / 多层评分体系；
- 直接把 Granger 检验写成真实因果传播；
- 全部歌曲两两计算相似性；
- 过度细化到月、日的历史分析；
- 把无监督聚类准确复原 20 个流派当成项目必须成功的目标。

推荐的模块关系如下：



如果由我来实施，我会采用方案 A，把项目做成“静态影响网络＋独立风格距离＋分时期演变＋匹配核验”这四个紧密衔接的部分。 我会把你现有的 Peer Network 经验用于数据连接、邻居比较和滞后特征构造，把额外数学深度放在 R4 的公平对照和 R5 的变化识别上。最需要避免的不是模型太简单，而是把同

名 ID 合错、把发行年份当创作年份、把回顾性关系当历史已知关系，再用复杂算法把这些问题掩盖掉。只要这几个基础处理扎实，这个题目完全可以在不使用极端复杂模型的情况下，做出完整、可解释、能在 Q&A 中站得住的项目。

来源文件索引

以下为本分析引用的工作文件。保持本 HTML 位于项目的 output 文件夹中时，可通过链接打开原始材料；移到其他位置后，仍可按相对路径查找。

1. ProblemC_2021ICM-D_The_Influence_of_Music.pdf
   Problems/ProblemC_2021ICM-D_The_Influence_of_Music.pdf
2. Final_Project_Guidelines.pdf
   Final_Project_Guidelines.pdf
3. influence_data.csv
   Problems/ProblemC_Music_data/influence_data.csv
4. full_music_data.csv
   Problems/ProblemC_Music_data/full_music_data.csv
5. data_by_artist.csv
   Problems/ProblemC_Music_data/data_by_artist.csv
6. data_by_year.csv
   Problems/ProblemC_Music_data/data_by_year.csv
7. D21018555.pdf
   References/C_2021ICM-D/D21018555.pdf
8. D21060286.pdf
   References/C_2021ICM-D/D21060286.pdf

本文件保留对话中的完整项目规划内容。公式与流程图已嵌入页面，离线阅读及打印无需加载外部资源。