2021 ICM Problem D《The Influence of Music》建模关键决策备忘

> 项目：MAT3300 Final Project
> 数据目录： `e:\26_fall\3300prj\data`
> 参考论文： `e:\26_fall\3300prj\MAT3300_Final_Project\References\C_2021ICM-D`

1. 题目概述

量化「音乐影响力」：理解先前音乐如何影响新音乐与新艺术家，识别演化的（evolutionary）与革命的（revolutionary）趋势。

7 个子任务：

1. 用 `influence_data` 建有向网络，定义「音乐影响力」参数，抽子网络并描述
2. 用音频特征开发「音乐相似度」度量，验证同流派内是否比跨流派更相似
3. 比较流派内/流派间的相似度与影响力；什么区分一个流派、流派如何随时间变化、流派之间是否相关
4. 判断 influence_data 中的 influencer 是否真的影响了 follower；哪些特征更「传染」
5. 识别音乐演化中的「革命」特征；哪些艺术家是「革命者」
6. 分析一个流派的演化过程，识别动态影响者
7. 表达音乐的文化影响（时间/环境），识别社会/政治/技术变化（如互联网）的痕迹

2. 数据事实与盲点（已实测）

文件	内容	规模
`full_music_data.csv`	逐首歌音频特征	98,340 首，1921–2020
`data_by_artist.csv`	按艺术家聚合	5,854 位艺术家
`data_by_year.csv`	按年份聚合	100 年（1921–2020）

文件	内容	规模
`influence_data.csv`	影响关系网络	42,770 条边，3,774 影响者 / 5,046 跟随者

4 个关键盲点：

1. **`full_music_data` 的 `artists_id` 是数组格式** `[178301]`，直接 join 会得到交集 0。清洗后方括号后的真实交集：
   - influence ∩ full_music = **5560**（5603 个艺术家里仅 43 个无音频特征）
   - influence ∩ data_by_artist = **5602**（几乎完全对齐）
2. **`genre` 标签只存在于 `influence_data`**， `full_music_data` / `data_by_artist` 里没有流派字段 → 第 2、3 问只能覆盖 ~5600 个艺术家。
3. **时间粒度不统一**： `influence_data` 只有 `active_start`（十年，1930–2010）， `full_music_data` 是具体 `year`（1921–2020）。
4. **4,410 首歌是多艺术家合作**（`artists_id` 含多个 id），一首歌会算到多个艺术家头上。

3. 建模主线

> **用「网络结构」刻画"谁影响了谁"，用「音频特征相似度」验证"影响是否真实发生"，再用时间维度区分"演化 vs 革命"。**

模块	对应题目	核心做法
A. 影响力网络	Q1	建有向图，算中心性，抽子网络
B. 相似度度量	Q2–3	特征标准化 → 距离度量，验证「同流派内 < 跨流派」， 画流派关系
C. 影响验证	Q4	比较 follower↔influencer 相似度 vs follower↔随机艺术家， 找传染特征
D. 革命与演化	Q5–6	时间序列突变检测找「革命」，挑一个流派做动态演化
E. 文化影响 +报告	Q7	用网络/特征的时间拐点对照社会技术事件

4. 关键决策点（按优先级排序）

决策 1：艺术家主键用哪张表？【必须先定】

- 推荐： `data_by_artist` （5,854 位）作为「艺术家锚点」，与 influence 几乎完全对齐； `full_music_data` 用来做歌曲级细节。

决策 2：相似度用什么度量 + 要不要降维？【核心】

- 特征量纲差异巨大（tempo≈100、loudness −60~0、其余 0~1），**必须先标准化**。
- 推荐：Z-score 标准化 + 余弦相似度（或马氏距离），先用全部 11 个音频特征，冗余再做 PCA。
- 分叉：保留原空间（学权重）vs 降维换空间（因子分析）。

决策 3：相似度分析在哪个粒度？

- 歌曲级（细，但有 4,410 首多艺术家污染）vs 艺术家级（ `data_by_artist` 均值，干净）。
- 推荐：艺术家级做第 2、3 问，歌曲级做第 4 问验证。

决策 4：「影响力」指标怎么定义？

- 纯网络中心性（PageRank / 介数 / 特征向量 / 三度影响力）？还是「相似度加权」的复合指标？
- 推荐：先算 PageRank + 出度，再决定是否引入相似度。

决策 5：「革命」的判定标准？【最模糊】

- 用 change point detection 在 `data_by_year` 序列上找特征突变？还是网络结构的剧烈重组？
- 需要先定一个可操作的阈值定义。

决策 6：时间约束怎么处理？

- 第 4 问验证「影响方向」时，influencer 的 `active_start` 必须 ≤ follower（否则因果倒置）。
- 要不要把 decade 精度细化到 year 需要定。

推进顺序建议：先定决策 1、2（后续所有模块都依赖），决策 5 放到最后。

5. 两篇获奖论文的决策对照

核心分野

	论文 1（2101855）	论文 2（2106028）
路线	**网络为王**：一切围绕「影响力」，相似度反过来服务影响力	**统计为王**：因子分析降维 + 假设检验 + 布林带，方法标准稳妥
标题	Measure of Influence and Similarity in **Dynamic Networks**	Mining ... based on **Social Network Analysis and Statistical Methods**

逐决策对照

决策点	论文 1	论文 2
1. 主键/对齐	以 `influence_data` 网络为核心（5599 节点，弃 4 孤立点）；1920s 归入 1930s	以 `influence_data` 建网；多艺术家合作只取第一位定流派
2. 相似度度量	**加权余弦距离**，权重用网络测地距离做标签、SGD 学出来	**因子分析降维到 3 维**，隐空间里用余弦相似度
3. 粒度	艺术家级（每十年平均），网络切 9 个时期的动态图	歌曲级做因子分析可视化，相似度矩阵算在艺术家/流派级
4. 影响力指标	**Rescaled PageRank**（解决时间偏差），再用相似度替换 indegree	**5 指标**（介数/特征向量/三度影响/忠诚度/流派多样性）+ 熵权法 EWM
5. 革命判定	双源：外部（特征趋势突变对照历史）+ 内部（革命者三标准）	**布林带 + 移动平均斜率**，3 component 同时突破 → 1961–1968
6. 时间约束	decade 粒度，过去影响几何衰减（β 折扣）	active_start 统计人数，特征按 year 画序列，3 年滑动窗口

「革命者」结论

- 论文 1：Billie Holiday、Muddy Waters、Bob Dylan、The Beatles、Little Richard
- 论文 2：The Beatles、Nat King Cole（革命期 1961–1968）

⚠️ 一个分歧点（机会）

Q4「哪些特征更传染」两篇结论不一致：

- 论文 1：valence、tempo（音乐性特征比 vocal 类型更易同步）
- 论文 2：acousticness、energy（摘要写 acousticness + valence，正文写 acousticness + energy）

→ 说明「传染性」结论对度量与检验方法敏感，是做出区分度的地方。

6. 方向建议

- **走「深度/差异化」** → 学论文 1：用网络结构反推特征权重、做时间偏差修正（Rescaled PageRank）。拿高分点，但实现复杂。
- **走「稳妥/可复现」** → 学论文 2：因子分析 + 余弦 + 熵权法 + 布林带，每步有标准统计依据。
- **推荐混合**：用论文 2 的因子分析/熵权法搭骨架（快、稳），再挑论文 1 的一个亮点（时间偏差修正，或「用网络距离验证相似度」）作创新点。